Eserciziario di comprensione

Context Cube, Walsh/Laplaciano, Bootstrap e Separate Learning

Percorso guidato attraverso le fasi 8B, 8R, 9B, 10C, 10D e 11A

Scopo. Non memorizzare formule isolate, ma riuscire a ricostruire il filo logico del progetto: come si passa da una funzione di qualita' sui subset di contesto a una descrizione spettrale, poi a una stima dell'incertezza, e infine a un modello dinamico con componenti dissipativa e rotazionale separate.

Versione preparata sul materiale e sui notebook sviluppati finora. La sezione 11A include esercizi basati anche sui risultati del notebook Phase 11A allegato.

Contents

1 Come usare questo eserciziario 2

2 Fase 0 - Subset, mask e Boolean cube 2

3 Fase 8B - Costruire un segnale misurabile 3

4 Fase 8R - Repeats e rumore di sampling 4

5 Fase 9B - Gold synthetic tasks 5

6 Fase 10C - Walsh analysis 7

7 Fase 10C - Laplaciano e heat flow 8

8 Fase 10D - Bootstrap e significativita' 9

9 Ponte teorico - Dal quadro "campo/flusso" a Phase 11A 10

10 Fase 11A - Separate learning 11

11 Fase 11A - Esercizi sui risultati reali del notebook allegato 13

12 Esercizi finali da ricerca 15

13 Foglio formule essenziale 17

14 Risultati di controllo essenziali 17

Come usare questo eserciziario

Lavora in tre passaggi: (1) risolvi senza notebook; (2) controlla con le formule o con Python; (3) prova a spiegare il risultato a parole. Se sai fare solo il calcolo ma non sai dire *che cosa misura*, l'argomento non e' ancora consolidato.

I livelli sono indicativi:

- **Base**: definizioni e calcoli essenziali.
- **Intermedio**: collegamenti fra oggetti matematici diversi.
- **Ricerca**: interpretazione, falsificazione, limiti sperimentali.

Fase 0 - Subset, mask e Boolean cube

Obiettivo: capire che cosa stiamo realmente analizzando quando scriviamo $F(S)$.

0.1 - Dimensione dello spazio

Con $n = 6$ evidence card, rispondi:

a) Quanti subset possibili esistono?

b) Quanti vertici ha il context-cube?

c) Quanti vicini ha ciascun vertice?

d) Quanti edge non orientati ha tutto Q_6?

Deriva la formula generale $|E| = d2^{d-1}$ invece di usarla soltanto.

0.2 - Decodificare un mask

Scrivi su 6 bit e individua le evidence attive per $m = 17$, $m = 16$, $m = 48$, $m = 63$.

Perche' 16 e 17 sono vertici adiacenti del cubo?

0.3 - Distanza di Hamming

Calcola la distanza fra $17 = 010001_2$ e $48 = 110000_2$.

Spiega che cosa significa questa distanza nel nostro esperimento.

0.4 - La funzione osservata

Spiega con parole tue la mappa

$$F : \{0,1\}^6 \to \mathbb{R}.$$

Che cosa sono S e $F(S)$? Perche' lavoriamo con una funzione scalare del contesto invece di analizzare direttamente il testo prodotto dal modello?

Fase 8B - Costruire un segnale misurabile

Obiettivo: capire perche' una metrica binaria puo' rendere la superficie artificiosamente piatta e perche' abbiamo usato `quality/token_f1`.

8B.1 - Exact match vs token-F1

Gold: "Albert Einstein". Il modello produce:

A) Albert Einstein

B) Einstein

C) Albert

D) Isaac Newton

Assegna prima l'exact match. Poi calcola o stima il token-F1. Quale metrica conserva piu' informazione per costruire $F(S)$?

8B.2 - Segnale piatto

Supponi $F(S) = 1$ per ogni S. Calcola $\min F$, $\max F$, $\mathrm{std}(F)$ e il numero di valori distinti. Ripeti con $F(S) = 0$ per ogni S.

Perche', dal punto di vista delle interazioni fra evidence, i due casi sono entrambi degeneri?

8B.3 - Full context puo' essere peggiore

Osservi

$$F(\varnothing) = 0, \qquad F(\text{full}) = 0, \qquad \max_S F(S) = 0.8.$$

E' una contraddizione? Proponi almeno due meccanismi che possono produrre questo comportamento. Uno deve coinvolgere *context interference / distractor sensitivity*.

8B.4 - Effetto marginale di una evidence

Definisci

$$\Delta_i(S) = F(S \cup \{i\}) - F(S).$$

Interpreta $\Delta_i(S) > 0$, < 0, $= 0$. Poi spiega perche' il segno puo' cambiare al cambiare di S.

8B.5 - Monotonicita'

Scrivi matematicamente la proprieta' "aggiungere evidence non peggiora mai la risposta".

Costruisci una funzione su due evidence che la viola.

8B.6 - Audit del prompt

Perche' confrontare $F(\varnothing)$ e $F(\text{full})$ non basta a escludere un leakage?

Quale informazione addizionale dovremmo salvare per poter verificare davvero che il mask 0 non contenga evidence?

Fase 8R - Repeats e rumore di sampling

Obiettivo: distinguere la superficie osservata una sola volta dalla superficie media del modello sotto una politica di decoding stocastica.

8R.1 - Conteggio esperimenti

Hai 3 query, 64 mask e $R = 4$ repeat per mask. Quante generazioni sono necessarie?

8R.2 - Stimare la media

Per un mask osservi $F_1 = 0$, $F_2 = 1$, $F_3 = 0.5$, $F_4 = 0$.

Calcola media, varianza campionaria e standard error della media.

8R.3 - Deterministico vs stocastico

Se il decoder usa `do_sample=False`, che cosa aggiungono 100 esecuzioni dello stesso prompt?

Perche' abbiamo distinto `deterministic_check` da `stochastic`?

8R.4 - Cambiare protocollo

La baseline originale e' deterministica; Phase 8R usa sampling stocastico. Perche' non e' corretto trattare ingenuamente tutte le osservazioni come IID dello stesso processo?

Quale variabile sperimentale e' cambiata?

8R.5 - Riduzione della varianza

Se una singola misura ha varianza σ^2, quanto vale approssimativamente $\mathrm{Var}(\hat{F})$ con R repeat indipendenti?

Quanto si riduce passando da $R = 4$ a $R = 16$?

Fase 9B - Gold synthetic tasks

Obiettivo: verificare che la pipeline sappia riconoscere interazioni che conosciamo a priori, prima di interpretare i dati reali.

9B.1 - Direct

Sia $F(x_1, x_2) = x_1$. Quale ordine di interazione ti aspetti? Perche' x_2 deve essere irrilevante?

9B.2 - AND non e' una pura interazione

Compila la tabella di $F(x_1, x_2) = x_1x_2$.

La funzione e' "ordine 2 puro" nella base Walsh? Motiva.

9B.3 - XOR come test pulito

Considera $x_1 \oplus x_2$ e ricodifica l'output in $\{-1, +1\}$.

Perche' questa versione e' un test particolarmente pulito di interazione di ordine 2?

9B.4 - Triple chain

Per $F = x_1x_2x_3$, qual e' il massimo ordine Walsh possibile?

Perche' possono comparire anche componenti di ordine inferiore?

9B.5 - Redundancy vs synergy

Confronta $F = x_1 \vee x_2$ con $F = x_1x_2$.

Descrivi in termini di evidence la differenza fra ridondanza e sinergia.

9B.6 - Entita' nonce

Perche' nei gold synthetic task usiamo nomi inventati come "Zorblax"?

Quale confondente vogliamo eliminare?

Fase 10C - Walsh analysis

Obiettivo: capire che lo spettro Walsh descrive a quale ordine combinatorio vive la variazione di F sul cube.

10C.1 - Componente DC

Se $F(S) = c$ per ogni S, quali coefficienti Walsh possono essere non nulli? Dove si trova tutta l'energia?

10C.2 - Energia totale e non-DC

Spiega la differenza fra

$$E_{\text{tot}} = \sum_{k=0}^{d} E_k, \qquad E_{\text{int}} = \sum_{k=1}^{d} E_k.$$

Perche' e' utile guardare E_k/E_{int} quando vogliamo studiare le interazioni?

10C.3 - Leggere uno spettro

Supponi

$$(E_1, E_2, E_3, E_4) = (0.10, 0.30, 0.40, 0.20).$$

Calcola le frazioni non-DC. Quale ordine domina? Quale conclusione puoi trarre e quale, invece, sarebbe un'interpretazione eccessiva?

10C.4 - Funzione logica sparsa

Una funzione e' nonzero solo quando $x_4 = 1$ e $x_1 = x_2 = x_3 = x_5 = 0$, mentre x_0 e' libero.

Scrivila come prodotto usando x_i e $(1 - x_i)$. Perche' una funzione cosi' sparsa puo' avere energia a molti ordini?

Fase 10C - Laplaciano e heat flow

10C.5 - Spettro del 6-cube

Per Q_6, gli autovalori sono $\lambda_k = 2k$ con molteplicita' $\binom{6}{k}$.

Costruisci la tabella completa per $k = 0, \dots, 6$ e verifica che le molteplicita' sommino a 64.

10C.6 - Energia di Dirichlet

Spiega o dimostra

$$f^\top L f = \sum_{\{u,v\} \in E} (f(u) - f(v))^2.$$

Che cosa misura intuitivamente sul context-cube?

10C.7 - Perche' la prima Phase 10 era piatta

Mostra che se $f = c\mathbf{1}$, allora $Lf = 0$ e $f^\top L f = 0$.

Collega questo risultato al fatto che sensitivity e high-order Walsh energy erano nulle.

10C.8 - Heat kernel

Se $Lv_k = \lambda_k v_k$, mostra che

$$e^{-tL} v_k = e^{-t\lambda_k} v_k.$$

Con $\lambda_k = 2k$, confronta il decadimento di $k = 1$, $k = 3$ e $k = 6$.

Idea chiave da saper spiegare:

$$\boxed{\text{ordine di interazione alto} \longleftrightarrow \text{frequenza alta sul grafo}}$$

Il heat flow elimina rapidamente le componenti ad alta frequenza; sul Boolean cube queste corrispondono agli ordini Walsh piu' alti.

Fase 10D - Bootstrap e significativita'

Obiettivo: capire quali strutture del cube sopravvivono al rumore delle generazioni.

10D.1 - Resampling per mask

Perche' nel bootstrap ricampioniamo separatamente $F_1(S), \dots, F_R(S)$ per ogni S, invece di mischiare tutte le osservazioni dei 64 mask?

10D.2 - Query sparsa

Un unico mask ha osservazioni $[0, 0, 1, 1]$ e tutti gli altri mask sono sempre zero.

Qual e' la probabilita' che un bootstrap di dimensione 4 estragga quattro zeri da quel mask? Perche' questo motiva $P_{\text{boot}}(F^{(b)} \equiv 0)$?

10D.3 - Spectrum conditioning

Perche' E_k/E_{nonDC} non ha senso se $E_{\text{nonDC}} = 0$?

Spiega perche' i CI dello spettro normalizzato vanno condizionati alla superficie non-degenere.

10D.4 - Segno stabile

Confronta due effetti:

$$\Delta_3 = -0.28, \quad CI = [-0.35, -0.22],$$
$$\Delta_2 = 0.04, \quad CI = [-0.07, 0.14].$$

Che cosa puoi dire dei due bit senza sovrainterpretare il CI?

10D.5 - Rumore e Laplacian energy

Se $\hat{f} = f + \epsilon$, perche' $\hat{f}^\top L \hat{f}$ tende a essere maggiore di $f^\top L f$?

Spiega l'idea usando differenze fra vertici adiacenti.

10D.6 - Bias quadratico

Nel d-cube ogni vertice appartiene a d edge. Deriva intuitivamente

$$\widehat{\text{bias}}_{\text{noise}} \approx d \sum_S \text{Var}[\bar{F}(S)].$$

Parti da $\sum_{\{u,v\}} (\epsilon_u - \epsilon_v)^2$ e assumi rumore indipendente fra mask.

Ponte teorico - Dal quadro "campo/flusso" a Phase 11A

Nel materiale teorico avevamo identificato la corrente informativa con $\dot{z}$ e introdotto una matrice di risposta anisotropa Σ, ottenendo una generalized gradient flow $\dot{z} = -\Sigma \nabla U$. Avevamo poi distinto una parte di gradiente da una parte rotazionale e introdotto dissipazione e rumore. Questa sezione traduce quelle intuizioni in esercizi matematici verificabili.

T.1 - Gradient flow generalizzato

Sia

$$\dot{z} = -M \nabla U, \qquad M = M^\top \succeq 0.$$

Calcola dU/dt e mostra che e' non positivo. Interpreta geometricamente il risultato.

T.2 - Antisimmetria

Se $A^\top = -A$, dimostra che per ogni x reale vale $x^\top A x = 0$.

Suggerimento: lo scalare e' uguale al proprio trasposto.

T.3 - Rotazione senza discesa del proprio potenziale

Per

$$F_{\text{rot}} = A\nabla H,$$

calcola $dH/dt = \nabla H^\top F_{\text{rot}}$. Usa T.2.

T.4 - Geometria

Spiega la differenza fra $-M\nabla U$ e $A\nabla H$ usando le parole: discesa, dissipazione, curvatura, circolazione, traiettoria.

T.5 - Verso la SDE

Passa da $\dot{z} = F(z)$ a

$$dz = F(z)\,dt + G(z)\,dW_t.$$

Quali due aspetti distinti del processo descrivono F e $GG^\top$?

Fase 11A - Separate learning

Obiettivo: capire se una rete puo' separare un campo dissipativo e uno rotazionale quando la decomposizione vera e' nota.

Nel notebook 11A il ground truth e'

$$F^\star = -M^\star\nabla U^\star + A^\star\nabla H^\star,$$

con

$$U^\star(x,y) = \tfrac{1}{2}x^2 + y^2 + 0.05x^4, \qquad H^\star(x,y) = \tfrac{1}{2}(x^2+y^2),$$
$$M^\star = \begin{pmatrix} 1 & 0.2 \\ 0.2 & 0.7 \end{pmatrix}, \qquad A^\star = \begin{pmatrix} 0 & -1.25 \\ 1.25 & 0 \end{pmatrix}.$$

11A.1 - Calcolo esplicito

Calcola $\nabla U^\star(1,1)$, $\nabla H^\star(1,1)$, poi $F^\star_{\text{diss}}(1,1)$ e $F^\star_{\text{rot}}(1,1)$. Infine somma le due componenti.

11A.2 - Dissipazione al punto $(1,1)$

Calcola $\nabla U^\star \cdot F^\star_{\text{diss}}$ nel punto $(1,1)$.

Perche' il segno e' piu' informativo del semplice disegno delle frecce?

11A.3 - Conservazione rotazionale

Calcola $\nabla H^\star \cdot F^\star_{\text{rot}}$ nello stesso punto.

Quale proprieta' strutturale di $A^\star$ forza questo valore?

11A.4 - PSD by construction

Nel modello si usa $M_\theta = LL^\top + \epsilon I$. Dimostra che $x^\top M_\theta x > 0$ per $x \neq 0$ se $\epsilon > 0$.

11A.5 - Skew by construction

Se $A_\theta = B - B^\top$, dimostra $A_\theta^\top = -A_\theta$.

11A.6 - Tre modelli, tre ipotesi

Confronta:

$$F_{\text{plain}} = \text{MLP}(z), \qquad F_{\text{diss}} = -M\nabla U,$$
$$F_{\text{struct}} = -M\nabla U + A\nabla H.$$

Quale ipotesi scientifica testa ciascun modello? Quale dovrebbe fallire se la circolazione e' essenziale?

11A.7 - Identificabilita'

Perche' non e' necessario che il valore numerico di A_θ coincida con $A^\star$ per dichiarare che la componente rotazionale e' stata appresa bene?

Ragiona sul fatto che A e ∇H possono compensarsi per scala.

11A.8 - One-step vs rollout

Due modelli hanno MSE locale simile. Uno segue la spirale vera per 100 step; l'altro diverge lentamente. Quale e' migliore come modello dinamico e perche'?

Fase 11A - Esercizi sui risultati reali del notebook allegato

Questi esercizi usano i risultati effettivamente salvati nel notebook 11A allegato. Servono a separare *fit del campo totale*, *correttezza strutturale* e *recupero delle componenti*.

I test MSE osservati sono circa:

Modello	Test MSE	Nota
Plain MLP	6.7×10^{-5}	campo totale non strutturato
Dissipative-only	6.98×10^{-1}	non puo' rappresentare bene la circolazione
Structured	2.15×10^{-4}	dissipativo + rotazionale

Per lo structured model il notebook riporta inoltre:

$$\cos(F_{\text{diss}}, F^{\star}_{\text{diss}}) \approx 0.941, \qquad \cos(F_{\text{rot}}, F^{\star}_{\text{rot}}) \approx 0.945,$$
$$\lambda_{\min}(M_\theta) \approx 0.704, \qquad \|A_\theta + A_\theta^\top\| = 0,$$
$$\text{mean } |dH/dt|_{\text{rot}} \approx 8.8 \times 10^{-8}.$$

11A.R1 - Chi vince sul solo MSE?

Ordina i tre modelli per test MSE. Perche' questa classifica da sola non basta per decidere quale architettura e' piu' utile scientificamente?

11A.R2 - Perche' il dissipative-only fallisce?

La sua MSE e' circa quattro ordini di grandezza peggiore del plain MLP. Collega questo risultato alla geometria del ground truth.

11A.R3 - Struttura vs accuratezza

Lo structured model ha MSE leggermente peggiore del plain MLP, ma cosine similarity delle due componenti circa 0.94**.**

Che cosa sta comprando la struttura in cambio di una piccola perdita di accuratezza sul campo totale?

11A.R4 - Vincoli strutturali

Interpreta $\lambda_{\min}(M_\theta) \approx 0.704 > 0$ **e skew error** $= 0$**.**

Sono risultati appresi o garantiti dalla parametrizzazione? Quale parte resta comunque da verificare empiricamente?

11A.R5 - Conservazione della componente rotazionale

Che cosa significa avere mean $|dH/dt|_{\text{rot}} \approx 8.8 \times 10^{-8}$?

Perche' questo e' un test diverso dalla cosine similarity con la componente vera?

Il notebook riporta inoltre i seguenti rollout RMSE (tre condizioni iniziali):

Modello	IC0	IC1	IC2
Plain	0.00343	0.00383	0.00214
Dissipative-only	0.19361	0.41865	0.40211
Structured	0.00434	0.00680	0.00255

11A.R6 - Rollout

Quale conclusione supportano questi numeri sulla necessita' della componente rotazionale?

Perche' plain e structured possono entrambi integrare bene pur avendo interpretabilita' molto diversa?

11A.R7 - Il parametro A non coincide con il ground truth

Nel notebook il parametro scalare appreso della matrice antisimmetrica e' circa 0.369**, mentre il ground truth usa** 1.25**. Eppure la cosine similarity rotazionale e' circa** 0.945**.**

Spiega come questo sia possibile senza contraddizione.

Domanda critica. Il notebook 11A mostra che il modello structured recupera bene la *direzione* delle componenti, ma le MSE delle componenti separate restano circa 0.305. Che cosa ti suggerisce questo sulla distinzione fra orientamento geometrico e scala/magnitudine? Proponi una metrica addizionale che useresti nella fase successiva.

Esercizi finali da ricerca

R.1 - Ricostruisci il progetto

In massimo 15 righe, spiega la catena

$$8B \to 8R \to 9B \to 10C \to 10D \to 11A.$$

Per ogni freccia indica quale limite della fase precedente motiva quella successiva.

R.2 - Non confondere due livelli

Perche' osservare high-order interactions in $F(S)$ non dimostra che nel latent space esista una componente rotazionale?

Quale tipo di esperimento serve per collegare le due cose?

R.3 - Disegna Phase 11B

Partendo da

$$dz = [-M\nabla U + A\nabla H]dt + G\,dW_t,$$

proponi una metrica separata per valutare: (i) drift dissipativo, (ii) drift rotazionale, (iii) diffusione $GG^\top$.

R.4 - Falsificazione

Scrivi tre risultati sperimentali che ti farebbero concludere che la decomposizione dissipativa/rotazionale non aggiunge valore rispetto a un vector field non strutturato.

Foglio formule essenziale

Boolean cube

$$|V(Q_d)| = 2^d, \qquad |E(Q_d)| = d2^{d-1}.$$

Effetto marginale

$$\Delta_i(S) = F(S \cup \{i\}) - F(S).$$

Energia Laplaciana

$$f^\top L f = \sum_{\{u,v\} \in E} (f_u - f_v)^2.$$

Heat flow

$$f_t = e^{-tL} f_0.$$

Cube spectrum

$$\lambda_k = 2k, \quad \text{mult}(\lambda_k) = \binom{d}{k}.$$

Dissipazione

$$F_{\text{diss}} = -M\nabla U, \qquad M = M^\top \succeq 0,$$

$$\frac{dU}{dt} = -\nabla U^\top M \nabla U \leq 0.$$

Rotazione

$$F_{\text{rot}} = A\nabla H, \qquad A^\top = -A,$$

$$\nabla H^\top A \nabla H = 0.$$

Structured drift

$$F = -M\nabla U + A\nabla H.$$

Stochastic extension

$$dz = F(z,t)dt + G(z,t)dW_t.$$

Risultati di controllo essenziali

Questa pagina non contiene soluzioni complete, solo valori utili per controllare i calcoli dopo aver provato da solo.

- 0.1: $|V| = 64$, grado $= 6$, $|E| = 192$.
- 0.2: $17 = 010001_2$; 16 e 17 differiscono in un solo bit.
- 8R.1: 768 generazioni.
- 8R.2: media $= 0.375$; varianza campionaria ≈ 0.2292; standard error ≈ 0.2394.
- 10C.5: molteplicita' $1, 6, 15, 20, 15, 6, 1$.
- 10D.2: $(1/2)^4 = 6.25\%$.
- 11A.1: $\nabla U^\star(1,1) = (1.2, 2)$; $\nabla H^\star = (1,1)$; $F_{\text{diss}} = (-1.6, -1.64)$; $F_{\text{rot}} = (-1.25, 1.25)$; $F^\star = (-2.85, -0.39)$.
- 11A.3: $\nabla H^\star \cdot F^\star_{\text{rot}} = 0$.

Checkpoint finale. Se riesci a spiegare senza appunti queste quattro identita', hai il nucleo concettuale del progetto:

$$f^\top L f = \sum_{\{u,v\}} (f_u - f_v)^2,$$

$$f_t = e^{-tL} f_0,$$

$$\frac{dU}{dt} = -\nabla U^\top M \nabla U \leq 0,$$

$$x^\top A x = 0 \qquad (A^\top = -A).$$